

# Processador de Thesaurus

José Carlos Lima Martins A78821 and Miguel Miranda Quaresma A77049

University of Minho, Department of Informatics, Braga, Portugal  
e-mail: {a78821,a77049}@alunos.uminho.pt

**Resumo** Este documento serve de apoio ao desenvolvimento de um Processador Thesaurus explicando todas as decisões tomadas de modo a obter o mesmo. Inicialmente será explicada a estrutura dos ficheiros de entrada (extensão .mdic) bem como mostradas as decisões tomadas de modo a obter o produto final. Por fim, serão apresentados exemplos de utilização do mesmo.

## 1 Introdução

iiiiii Updated upstream O presente projeto (Processador de Thesaurus) visa ser um sistema de processamento de dicionários Thesaurus que recorre a expressões regulares (ERs) para filtrar e transformar os mesmos, extraíndo e tratando a informação mais relevante de forma eficiente. Para atingir este objetivo é usada a linguagem de filtragem e tratamento de dados **AWK** visto ser uma **DSL**(Domain Specific Language) com foco em dados semi-estruturados.

## 2 Preliminares

De modo a compreender melhor o desenvolvimento deste projeto é importante saber e compreender a estrutura dos dicionários (ficheiros .mdic). A estrutura de um dicionário pode ser dividido em três conceitos:

- linhas começadas por '#': comentários a ignorar
- diretivas gerais:
  - linhas começadas por '%dom: dominio': indica que até ao aparecimento de nova linha começada por '%dom:' todos os termos são de 'dominio', sendo dom uma relação e a sua inversa é voc
  - linhas começadas por '%inv: relação1 : relação2': indica que a relação1 tem como inversa a relação2
- linhas começadas por '%THE': indicam tabelas de relações, com as seguintes características:
  - a linha inicial possui as relações bem como as classes da coluna correspondente
  - cada linha tem 1 ou mais termos, menos a inicial que possui apenas relações e classes
  - os termos são separados por ':' daqueles com que se relacionam
  - a relação entre o termo da coluna 1 e da coluna N é dado pela relação N da linha inicial

- na presença de vários termos com a mesma relação, podem ser agrupados por '|'
- quando uma relação na linha inicial possui <classe, ou seja 'relação<classe', significa que o elementos dessa coluna são instancia da classe
- quando '%THE<classe' significa que o termo 1 é instancia da classe

Pode-se finalmente, passar ao desenvolvimento do processador Thesaurus.

### 3 Desenvolvimento

#### 3.1 Exe 1

O processamento iniciou-se pela identificação dos domínios e relações presentes no dicionário. Para tal, e tendo em conta a estrutura dos documentos, foi usado como **Field Separator** o carácter ':'. Tendo a conta a sintaxe de Padrão → Ação inerente ao AWK foram considerados relevantes os seguintes padrões:

1. /%dom/: padrão que identifica novo domínio no início de uma linha
2. /%THE/: padrão que identifica início de tabela de relações indicadas na presente linha

No caso do padrão /%dom/ a ação compreende a remoção de espaços que precedam o domínio e o armazenamento do mesmo numa matriz **ind**.

```
/^%dom/      {sub(/^ /,"",$2); ind[0][$2]++}
```

Quando é encontrado o padrão /%THE/ são percorridos todos os campos (**i.e.**relações) e quando um dada relação não vazia (\$j!=' ' '&& \$j!=' ' ' ') é encontrada são-lhe removidos os espaços precedentes e subsequentes removendo também, eventualmente, a indicação de classe. De seguida estas são também armazenados na matriz **ind**.

```
/^%THE/      {for(j=2;j<=NF;j++){
                if($j != " " && $j!=""){
                    sub(/^ /,"",$j);
                    sub(/(\s)|(<(.*)?)/,"",$j);
                    !ind[1][$j]++;
                }
            }
        }
```

Por fim, quando o final de ficheiro é encontrado (EOF) são impressos os domínios e as relações recorrendo, para isso, às funções **printDominios** e **printRelations** respetivamente.

#### Usage

### 4 Conclusão